AI6127 项目报告修改与改进清单

供 Group 2 修改报告使用　2026 年 11 月 5 日

原报告的结构、语料说明、主要检索结果和分类成绩可以保留。当前重点是更新检查器实验，统一弃答、耗时和成本的统计口径，并说明仍未完成的消融与交付事项。下文页码均对应原版 2(1).pdf，修改建议尚未合并进原文。

1 优先替换检查器实验与相关结论

原报告第 10 至 11 页 第 5.2 节与 Table 11

旧实验分别重新生成摘要，不能隔离检查器的作用：旧 v1 与无检查器组的 40 份草稿均不同，旧 fixed 有 39 份不同。主表应改用同 40 个问题、同检索评论、同 240 句冻结草稿的配对实验，只改变是否启用检查器。旧三组结果可移入历史调试说明。

指标	Checker off	Checker on
Faithfulness	0.9731	0.9661
Answer relevancy	0.8435	0.8373
Context precision	0.8305	0.8472
Context relevance	0.9875	0.9875

四项指标均有 40 个有效配对，无裁判失败、无弃答。结论应写为“本次配对实验未观察到答案质量提升”。Context precision 使用答案作为参照；两组检索内容完全相同，不能将该指标上升解释为检索改善。

原报告第 10 页 Figure 6

更新为保留 215 句、无法验证 23 句、部分支持 2 句，保留率 89.58%，40 个问题均保留了回答。移除的 25 句是模型辅助标记，尚无独立人工判定，不能称为 25 条真实幻觉，也不能直接称为 25 条误删。

原报告第 1 页摘要 第 11 页净效果与结论

同步更新摘要与结论，删除旧非配对结果中的 p=0.047 及因果解释。“增加 2.0 秒”不再作为独立效果估计；可写“最终配对实验的检查阶段平均约 2.78 秒”。将“验证没有价值”收窄为本次实验未证明质量收益。

原报告第 10 页 相机对焦示例

删除“slow focus 不在引用评论中”的解释。旧 fixed 的 Q004 实际引用了 31395056d84f_0，原文含 “the focus takes forever”，检查器证据也包含这句。该例不能证明成功发现了编造内容。

2 统一评估口径和性能说明

原报告第 9 页 第 4.7 节与 Table 9

旧 BM25、Dense、Learned fusion 分数可保留，但需标为历史评估结果。旧 BM25 有 2 题未生成摘要，却将界面占位文字送去评分并得到 0；实际有答案的是 38/40。不要继续写成“RAGAS 统一将弃答记为 0”。

当前评估器将弃答单列，对 faithfulness、answer relevancy 和依赖答案的 context precision 跳过评分，并报告有效样本数、覆盖率和失败数。旧表尚未按新协议重跑，不能与新配对结果拼成同一次实验。Context precision 与检索精度共同上升只是该批历史数据中的现象。

原报告第 3 和 5 页 第 2.2 节与 Table 4

原五问已经展示检索结果摘要，可保留为检索功能示例。建议另补最新五问的生成答案摘录、引用、好评比例和完整流程耗时。新五问不是旧表中的中文、别名和比较问法，不能把下列时间直接填进旧表。

最新完整流程测试	耗时 秒
Q001 Galaxy S10 相机	8.592
Q007 Galaxy S10 续航	8.495
Q014 iPhone X 屏幕与触控	8.932
Q021 Pixel 4a 应用性能	8.322
Q032 iPhone 11 运营商与 SIM 兼容	10.070

原报告第 9 至 10 页 第 4.8 节与 Table 10

最新五问均值 8.882 秒、中位数 8.592 秒，包含查询改写、检索、重排、分类、总结和检查；应用响应缓存关闭。索引与模型加载 4.652 秒、本地预热 0.264 秒另计，模型权重已缓存，不能称为干净环境冷启动。

原 1.80 秒是检索流程，原 6.005 秒是检索之后的下游流程，均不能与 8.882 秒直接作快慢比较。6.75 问/分钟是串行估算，尚无并发压力测试，不能写成实测吞吐能力或可扩展性证明。

原报告第 10 页 Cost 与 Scalability

原¥3.99、¥1.03 和约¥3 若保留，应标为未核实的历史费用记录。最终批次可报告：40 问检查器估算 US$0.01612，五问下游分类、总结和检查估算 US$0.00581。两者均不含查询改写、RAGAS、早期试跑和本地算力，也不是账户账单。

缓存节省费用只在应用缓存开启，且输入、模型、参数及缓存版本一致时成立。最终测速关闭了应用响应缓存，服务端缓存仍可能存在。

3 补充统计修复与验证依据

原报告第 7 至 8 页 第 4.2 节

好评比例公式及分母说明可保留。补充按稳定产品标识合并同一手机的拼写别名，同时保留 Plus、5G、FE、Ultra 等不同型号。200 份旧结果仅重算聚合统计，其中 8 份发生数值变化；未重新生成情感预测，也未改标签。

Learned 配置中的示例	修正后的好评比例
Q012 同一机型别名合并	3/10 = 30.00%
Q030 同一机型别名合并	3/7 = 42.86%

统计单位是与所问方面相关的独立原始评论 doc_id。分母含正面、负面、混合和相关中立评论，排除方面未出现的记录；结果仅代表检索样本，不代表总体消费者满意度。

原报告第 8 至 9 页 第 4.5 至 4.6 节及 Tables 7 和 8

原分类表 31 个数值与最新重算一致，三位小数可以保留。1,200 条原样本、1,194 条有效金标及人工标签均未变。最新成绩是沿用已有预测重新评分，不应写成重新调用 API 预测了全部样本。可补入 VADER 基线比较。

分类器	Accuracy	Macro F1
DeepSeek	0.9389	0.8646
VADER	0.6248	0.3895

VADER 不能输出 mixed，四分类比较存在能力范围差异。保留 neutral 仅 31 条、召回率 17/31 = 0.5484，以及 142 处分歧采用首位标注者标签的限制。代码修复不等于人工仲裁质量已得到改进。

建议新增一段本地验证说明

147 项自动化测试通过，无失败、错误或跳过；另有 59 个 subtests，JUnit 共记录 206 个 case，勿重复相加。验证覆盖产品别名、无效证据、旧缓存隔离、弃答与失败、评分输入一致性及计时。另完成 200 份统计重算、40 问配对实验和 5 问完整流程实测。

原报告第 10 页 第 5.1 节

将检查顺序改为：先验证引用 ID，模型返回判断及证据后，再检查引句。任一无效证据都会使相应句子降为无法验证，独立句子不受牵连；新增版本化缓存，防止旧判断绕过修复。服务失败与正常弃答分别记录。

原报告第 2 页 第 5 页 第 6 页的实现用语

第 2 页 mentions_other_model 是元数据标记，不能写成已自动阻止错误归属。第 5 页 BM25 可写“在允许的行中选择排名结果”，当前并非只计算这些行的分数。第 6 页将“K different reviewers”改为“K distinct reviews”，doc_id 去重不能证明用户互不相同。

4 仍需完成的工作与交付核对

下游创新的各项及组合消融

第 10 页声明了方面分类、引用和检查器三项下游创新，目前只有检查器完成了受控消融。课程 Q5 要求多项创新展示各项及组合贡献，因此方面分类与引用的消融仍未完成；检索的八配置消融不能替代这部分。若暂不补实验，应保留明确限制，不能仅修改措辞就称为全部完成。

方面级分类与检查器的人工评价

现有分类金标按整段评论标注，尚不能证明方面是否出现和方面情感判断的准确率。检查器 25 条标记也尚未经独立人工确认。建议后续建立方面级评价集，人工核对被保留和被移除的句子，分别估计漏检与误拒；本轮维持原标签不变。

结论中的其他限制

保留 40 题规模较小、检索题曾用于开发、生成器与自动裁判来自同一服务的限制。宽松引句匹配只能作为待测试的改进方向；代码已经做了部分 Unicode 与空白规范化，不能直接断言忽略标点即可消除大多数误拒。

原报告第 11 页 第 8 节的代码与数据入口

公开 GitHub 的 main.zip 仍对应旧版本，当前修复和新实验只在本地包中。报告若采用新结果，最终应给出对应版本的代码、依赖、README 及实验数据下载入口，并核验接收者权限。按当前安排先保存在本地，上传与最终链接补充尚未完成。

复现说明应引用已锁定依赖及 uv sync --all-groups，并注明新测试结果目录 results/local_validation_20261105。旧历史结果与最终配对结果应分别命名，避免混用 initial 或 before_cache_isolation 批次。

可保留的内容

保留语料清洗与统计主体、主要检索消融结果、分类 Tables 7 和 8 及混淆矩阵、好评比例公式和既有人工标注。Figure 1 可保留为历史界面示例，但截图耗时不作为最新版性能结论。原 Table 9、Table 10 若保留，须标明历史版本与统计范围。

核对依据与文件定位

原报告：2(1).pdf，共 12 页。最新数字：本地修复代码包中的 results/local_validation_20261105/VALIDATION_REPORT.md、paired_comparison.json、classification/、statistics/、end_to_end/ 和 usage_estimates.json。

对焦示例：results/group_c/b40/B40_learned_checker_fixed/Q004.json。课程要求核对：work/audit_20261105/course_findings.txt。以上为可复核位置，转交组员时应同时提供对应本地代码与结果包。